

On Data Distribution Leakage in Cross-Silo Federated Learning

2024 TKDE ——跨孤岛联邦学习中的分布推断攻击

文献分享

2026 年 5 月 6 日

Agenda

1.1 跨孤岛联邦学习 (Cross-Silo FL)

应用场景：多家机构（如医院、银行等“孤岛”）希望联合训练一个全局模型，但受限于隐私法规，彼此之间不直接共享本地数据。

传统 FL 的隐私承诺：

- 客户端在本地计算梯度 (Gradients)。
- 仅将“更新参数”上传给中心服务器聚合。
- **错觉：**只要原始数据不出本地，隐私就绝对安全。

本文提出的核心威胁

诚实但好奇的服务器 (Honest-but-curious Server)：

中心服务器遵守协议聚合模型，但在暗中截获并分析各机构上传的梯度更新，试图窃取高价值的商业机密——**本地数据的宏观分布 (Data Distribution)**。

2.1 战场转移：从单一白盒到联邦交互

与针对单一白盒模型的静态权重推断不同，本篇论文面临着全新的挑战环境：

- **动态的梯度视角**：攻击者不再拥有最终的静态模型权重，而是只能观察到训练过程中每一轮的动态梯度更新 (ΔW)。
- **无先验知识要求 (Zero Prior Knowledge)**：传统的属性推断通常需要攻击者具备辅助数据集来训练影子模型，而本文致力于在无辅助数据的情况下直接恢复分布。

2.2 为什么差分隐私 (DP) 防不住分布泄露？

工业界通常采用 **DP-SGD** 来防御反演攻击，即在梯度中注入高斯噪音隐藏个体贡献。

DP 的盲区 (DP's Blind Spot):

- **微观保护:** DP 严格保护了特定个体不被识别。
- **宏观暴露:** DP 的理论基础在于保留群体的统计可用性。这意味着，代表宏观统计规律的“数据分布”，在加上 DP 噪音后，依然能被强力的推断算法重构出来！

[请插入 DP 盲区示意图]

建议：论文中展示个体保护与全局分布泄露对比的图表。

3.1 分布窃取框架全景图

针对神经网络的攻击流程：

- ① **梯度截获**：服务器收集特定轮次上传的梯度 g_t 。
- ② **特征重构优化**：利用梯度信息，通过优化算法反向推导类别的先验分布。
- ③ **标签分布提取**：结合特征分布和损失函数的解析，精算各标签在孤岛中的具体占比。

[请插入核心 Attack Framework 图]

讲解重点：展示服务器如何利用 g_t 一步步反推出特征分布和标签分布的逻辑。

4.1 突破最强防御：DP-SGD 实验验证

本论文最具冲击力的实证结果之一：

防御失效：

- 在客户端开启 DP-SGD 并注入不同级别的隐私噪音（不同 ϵ 值）后执行攻击。
- 结论：尽管噪音足以掩盖单一样本特征，但由于“分布”是全局统计量，对零均值噪音具有天然的鲁棒性。攻击者依然能精准测算出客户端数据分布。

[请插入 DP 噪音级别与误差曲线图]

解读：展示即使隐私预算 ϵ 很小，分布推断的准确率依然居高不下。

5.1 研究启示与未来防御方向

核心结论 (Takeaways)

- **盲点暴露**：现有的联邦学习隐私保护（如 DP）主要聚焦于“微观个体”，严重忽视了跨孤岛场景下“宏观分布”泄露的商业危害。
- **梯度的双刃剑**：梯度不仅传递了模型优化的方向，也潜藏了丰富的数据全局统计特征。

未来的潜在防御思路：

- 针对梯度的分布混淆技术 (Distribution Obfuscation)。
- 结合安全多方计算 (SMPC) 的高级聚合策略。

Q & A

感谢聆听！