

On Data Distribution Leakage in Cross-Silo Federated Learning

2024 TKDE ——跨孤岛联邦学习中的分布推断攻击

文献分享

2026 年 5 月 6 日

Agenda

1. 前置知识 (Preliminaries)
2. 问题陈述与威胁模型 (Problem Statement)
3. 核心攻击方法论 (Attack Methodology)
4. 实验评估与防御分析 (Evaluation & Defense)
5. 总结与启示 (Conclusion)

1.1 联邦平均算法 (FedAvg) 机制

联邦学习通过在不交换原始数据的情况下协作训练模型，其核心是 FedAvg 算法：

角色动作分解

- **客户端 (本地训练)**：寻找最优参数 $\theta_k^{(t)}$ 以最小化本地经验风险：

$$\theta_k^{(t)} = \arg \min_{\theta} \frac{1}{n_k} \sum_{i=1}^{n_k} \ell(f(\mathbf{x}_i; \theta), y_i) + R(\theta) \quad (1)$$

- **服务器 (全局聚合)**：按照数据量占比对各方上传的参数进行加权平均：

$$\theta_G^{(t)} \leftarrow \sum_{k=1}^N \frac{n_k}{n} \theta_k^{(t)} \quad (2)$$

注：服务器截获的正是客户端每一轮上传的“赃物” $\theta_k^{(t)}$ 。

1.2 差分隐私的理论局限：Group DP 与分布泄露

差分隐私 (DP) 虽然保护了微观个体，但在保护宏观分布时面临“数学死局”：

- **个体的防御** ($s = 1$): DP 保证增加/删除一条记录对输出影响微乎其微 (受 e^ϵ 限制)。
- **群体的泄露** (s records): 为了改变数据分布，通常涉及 s 条记录的变动。根据 **Group DP** 性质，隐私边界呈指数级爆炸：

$$\Pr[\mathcal{A}(D) \in \mathcal{O}] \leq e^{s\epsilon} \cdot \Pr[\mathcal{A}(D') \in \mathcal{O}] \quad (3)$$

- **死局**: 若要强化掩盖 $s = 1000$ 人的分布差异，必须将 ϵ 设得极小 (如 $1/s$)，这会导致注入的加噪量“排山倒海”，使模型精度 (Utility) 彻底归零。

2.1 分布推断的核心动机：捕捉“偏见”

为什么能从参数中看穿分布？——利用“本地偏好”与“全局中庸”的分歧。

- 本地模型的“偏科”：客户端 k 的模型仅在本地数据分布（如 $[-1, 3]$ ）上表现优异，在缺失分布上会产生极大的预测偏差。
- 全局模型的“全能”：聚合后的模型见多识广（如 $[-3, 3]$ ），对全域都有稳定的泛化能力。
- 攻击点：寻找本地模型与全局模型“吵架”（分歧最大）的地方，即可反推出该客户端缺失了哪些分布的数据。




Fig. 1. Data distribution attack in cross-silo FL.

2.2 攻击目标与特权服务器

- **威胁模型**：诚实但好奇 (Honest-but-curious) 的服务器。不破坏协议，但记录一切。
- **输入已知**：
 - ① $\mathcal{M}_k = \{\theta_k^{(t)}\}$ ：第 k 方上传的所有历史参数序列。
 - ② θ_G ：最终的全局模型。
- **终极目标**：在 ** 零先验知识 **（无影子数据集）的情况下，精准还原参与方 k 训练数据的特征分布 $P(X)$ 和标签分布 $P(Y)$ 。

3.1 第一步：参数时序聚合 (Algorithm 1)

难点：如何从 T 轮历史更新中提炼最关键的特征？

启发式权重聚合策略：

- ① **算分歧 (行 2)：**计算每轮本地参数与全局模型的欧氏距离：
 $C_k^{(t)} = \|\theta_k^{(t)} - \theta_G\|_2$ 。
- ② **分权重 (行 4)：**利用 **Softmax** 转换，分歧越大的轮次赋予越高权重。
- ③ **得输入 (行 5)：**得到“浓缩版”本地参数 θ_k 。

Algorithm 1: Aggregate Local Model Parameters.

Input: $\mathcal{M}_k = \{\theta_k^{(t)}\}_{t=1}^T$: local model parameters of the k -th party; θ_G : final global model parameters

Output: Aggregated local model parameters θ_k

```
1 for  $t = 1, \dots, T$  do
2    $C_k^{(t)} \leftarrow \|\theta_k^{(t)} - \theta_G\|_2$ ;
3 for  $t = 1, \dots, T$  do                                // Compute weights
4    $w_k^{(t)} \leftarrow \frac{\exp(C_k^{(t)})}{\sum_{j=1}^T \exp(C_k^{(j)})}$ ;           // Softmax
5  $\theta_k \leftarrow \sum_{t=1}^T w_k^{(t)} \theta_k^{(t)}$ ; // Aggregate local models
6 return  $\theta_k$ ;
```

3.2 方案 A: 针对可微模型的 PGDA (Algorithm 2)

Projected Gradient Descent Attack:

- **核心逻辑**: 求解一个 ** 梯度匹配 (Gradient Matching)** 优化问题。
- **流程**: 随机初始化虚拟分布 $\rightarrow$ 反向传播调整数据分布 $\rightarrow$ 使虚拟梯度不断逼近截获的真实梯度。
- **鲁棒性**: 引入高斯扰动筛选在噪音下依然表现一致的合成样本。

Algorithm 2: Projected Gradient Descent Attack.

Input: θ_k : local model parameters; θ_G : global model parameters; n : number of synthetic samples

Output: Synthetic data set S

```
1  $S \leftarrow \emptyset$ ;
2 while  $|S| < n$  do
3    $\mathbf{x}_0 \leftarrow \text{RANDSAMPLE}()$ ; // Random point
4   for  $t = 1, 2, \dots, \text{iter}_{\max}$  do
5      $\nabla \leftarrow \partial \mathcal{L}(\mathbf{x}_{t-1}; \theta_k, \theta_G) / \partial \mathbf{x}_{t-1}$ ;
6      $\mathbf{y}_t \leftarrow \mathbf{x}_{t-1} - \alpha_t \nabla$ ; // Gradient descent
7      $\mathbf{x}_t \leftarrow \underset{\mathbf{x} \in \mathcal{Q}}{\text{argmin}} \frac{1}{2} \|\mathbf{x} - \mathbf{y}_t\|_2^2$ ; // Projection
8   for  $i = 1, 2, \dots, r$  do
9      $\nu_i \sim \mathcal{N}(0, \sigma^2 \mathbb{I})$ ;
10     $\hat{\mathbf{x}}_i \leftarrow \mathbf{x}_t + \nu_i$ ; // Input perturbation
11     $\bar{\Delta} \leftarrow \frac{1}{r} \sum_{i=1}^r \Delta(f(\hat{\mathbf{x}}_i; \theta_k), f(\hat{\mathbf{x}}_i; \theta_G))$ ;
12    if  $\bar{\Delta} < \Delta_\tau$  then
13       $S \leftarrow S \cup \{\mathbf{x}_t\}$ ;
14 return  $S$ ;
```

3.3 方案 B: 针对不可微模型的通用攻击 (1/2)

算法 3: 外层合成循环

- **场景:** 针对决策树等无法求导的模型。
- **自适应机制:** 引入“宽容度”调节。如果当前阈值 τ_{min} 无法合成出有效样本, 则动态放松要求。
- **目标:** 通过不断迭代采样, 构建出一个统计特性上与真实分布吻合的样本集。

Algorithm 3: Generic Distribution Inference Attack.

Input: θ_k : local model parameters; θ_G : global model parameters; n : number of synthetic samples; τ_{min}^* : threshold; $fail_{max}$: timing of the relaxation of τ_{min} ; rej_{max} : max number of continuous rejections; d : number of features; d_{min} : minimum dimension of searching space

Output: Synthetic data set S

```
1  $S \leftarrow \emptyset$ ;  
2  $j \leftarrow 0$ ;  
3  $\tau_{min} \leftarrow \tau_{min}^*$ ; // Initial threshold  
4 for  $t = 1, 2, \dots, n$  do  
5    $x \leftarrow \text{Search}(\tau_{min})$ ;  
6   while  $x = \perp$  do // Failed to synthesize  
7      $x \leftarrow \text{Search}(\tau_{min})$ ;  
8      $j \leftarrow j + 1$ ;  
9     if  $j > fail_{max}$  then // Relax threshold  
10       $\tau_{min} \leftarrow 2 \cdot \tau_{min}$ ;  
11       $j \leftarrow 0$ ;  
12    $j \leftarrow 0$ ;  
13    $S \leftarrow S \cup \{x\}$ ;  
14 return  $S$ ;
```

3.4 方案 B: 针对不可微模型的通用攻击 (2/2)

算法 3: 核心 Search 函数

- 启发式搜索: 在离散特征空间中随机扰动并保留更优解。
- 维度缩减 (行 29-30): ** 核心创新点 **。当搜索空间太大导致无法收敛时, 算法会自动 ** 对半缩减 ** 特征维度 d , 在较低维的空间中寻找分布规律。

```
12    $j \leftarrow 0$ ;  
13    $S \leftarrow S \cup \{x\}$ ;  
14   return  $S$ ;  
15   Function Search( $\tau_{\min}$ ):  
16    $x^* \leftarrow \text{RANDSAMPLE}()$ ;  
17    $\tau^* \leftarrow \mathcal{L}(x^*; \theta_k, \theta_G)$ ;  
18    $j \leftarrow 0$ ;  
19   for  $t = 1, 2, \dots, \text{iter}_{\max}$  do  
20     if  $\tau^* < \tau_{\min}$  then  
21       return  $x^*$ ;           // Accept the sample  
22      $x \leftarrow \text{RANDSAMPLE}(x^*, d)$ ;           // Randomize  $d$   
23     features  
24      $\tau \leftarrow \mathcal{L}(x; \theta_k, \theta_G)$ ;  
25     if  $\tau < \tau^*$  then           // A better solution  
26        $x^* \leftarrow x$ ;  
27        $\tau^* \leftarrow \tau$ ;  
28        $j \leftarrow 0$ ;  
29      $j \leftarrow j + 1$ ;  
30     if  $j > \text{rej}_{\max}$  then           // Reduce search space  
31        $d \leftarrow \max(k_{\min}, \lceil d/2 \rceil)$ ;  
32        $j \leftarrow 0$ ;
```

3.5 PGDA 数学本质：基于梯度匹配的优化

攻击者通过最小化以下损失函数来“拟合”出真实的本地分布参数 $\mathbf{D}_{dummy}$ ：

$$\min_{\mathbf{D}_{dummy}} \mathcal{L}_{match} = \|\nabla W(\mathbf{D}_{dummy}, \theta) - \nabla W_{intercepted}\|^2 + \alpha \cdot \mathcal{R}(\mathbf{D}_{dummy}) \quad (4)$$

- **物理含义**：寻找一组数据分布，使其在当前模型 θ 下产生的梯度，与被截获的梯度 $\nabla W_{intercepted}$ 尽可能重合。
- **正则化项 $\mathcal{R}$** ：确保生成的分布满足基本的概率分布约束。

4.1 击穿最强防御：为什么 DP 失效了？

实验观察：

- **噪音的抵消效应：**虽然 DP 给每个梯度加了高斯噪音，但由于分布推断计算的是大量样本的 **** 均值/方差 ****，零均值的加性噪音在聚合运算中被自然“过滤”掉了。
- **结论：**现有的差分隐私防御，面对基于“统计平均”的分布推断攻击时，显得力不从心。

[此处建议插入]

[重构分布与真实分布对比图]

5.1 研究启示

核心结论 (Takeaways)

- **隐私盲点：**跨孤岛场景下，宏观商业情报（分布）的泄露危害不亚于个体隐私泄露。
- **算法鲁棒性：**PGDA 证明了分布信息具有极强的抗噪性，单一的 DP 机制不足以提供全面保护。
- **未来方向：**需要研究针对分布级信息的混淆机制。

Q & A

感谢聆听！