

On Data Distribution Leakage in Cross-Silo Federated Learning

2024 TKDE ——跨孤岛联邦学习中的分布推断攻击

文献分享

2026 年 5 月 6 日

Agenda

1. 背景与威胁模型 (Background & Threat Model)
2. 动机与挑战：从参数到梯度 (Motivation)
3. 核心攻击方法论 (Attack Methodology)
4. 实验评估与防御分析 (Evaluation & Defense)
5. 总结与启示 (Conclusion)

1.1 跨孤岛联邦学习 (Cross-Silo FL)

- **定义：**多个机构（如银行、医院）在不交换原始数据的情况下，协作训练一个共享模型。
- **交互流程：**
 - ① **本地训练：**客户端利用本地数据计算梯度 $\nabla L(x, y; \theta)$ 。
 - ② **参数同步：**客户端上传模型更新（梯度或权重差）至中心服务器。
 - ③ **全局聚合：**服务器执行 FedAvg（如权重平均）更新全局模型。
- **核心特征：**参与方数量少（Silo）、计算能力强、数据量大。

1.2 差分隐私 (Differential Privacy) 在 FL 中的应用

为了防止梯度泄露个体隐私，通常引入 **DP-SGD** 防御机制：

DP-SGD 核心步骤

- ① **裁剪 (Clipping)**：限制每个梯度向量的 ℓ_2 范数，防止单个极端样本主导更新。
- ② **加噪 (Noise Addition)**：在聚合梯度中注入高斯噪音 $n \sim \mathcal{N}(0, \sigma^2 C^2)$ 。

隐私承诺：攻击者无法以显著概率判断训练集中是否包含“张三”这一条特定记录。

2.1 什么是分布泄露？(Problem Definition)

攻击者的目标：

推断出参与方 k 的**全局统计分布**，包括：

- **特征分布 $P(X)$** ：数据在各特征维度上的均值、方差。
- **标签分布 $P(Y)$** ：训练集中正负样本的真实比例（极具商业价值）。

为什么是盲区？

DP 保护了个体，但为了保证模型可用性，它必须保留数据的统计特性。




Fig. 1. Data distribution attack in cross-silo FL.

2.2 诚实但好奇的服务器 (Threat Model)

- **服务器能力：**
 - 观察每一轮客户端上传的梯度更新。
 - 知道当前的全局模型参数 θ_t 。
 - **无先验知识：**攻击者没有参与方的辅助数据（无影子数据）。
- **防御假设：**客户端可能开启了裁剪和加噪形式的差分隐私防御。

3.1 攻击分类：根据模型性质因地制宜

两套推断机制

- **方案 A：针对可微分模型（如神经网络）**
 - 利用梯度作为优化约束，提出 PGDA（梯度分布攻击）。
 - 核心思想：寻找一组虚拟分布，使其产生的梯度与观测梯度最匹配。
- **方案 B：针对不可微分模型（如决策树、逻辑回归）**
 - 无法通过梯度求导，攻击者通过分析参数更新的数值特征，建立统计关联进行推断。

3.2 PGDA 工作流：如何从梯度逆推分布？

PGDA (Property/Prior Gradient Distribution Attack):

- ① 特征重构优化：初始化虚拟输入数据分布。
- ② 梯度匹配损失：计算虚拟数据产生的梯度与截获梯度的距离。
- ③ 反向传播更新：不断调整虚拟数据的分布参数，使 Loss 极小化。




Fig. 2. Workflow of PGDA.

3.3 PGDA 核心：基于梯度匹配的数学优化

攻击者求解以下优化问题来逼近真实分布：

$$\min_{\mathbf{D}_{dummy}} \mathcal{L}_{match} = \|\nabla W(\mathbf{D}_{dummy}, \theta) - \nabla W_{intercepted}\|^2 + \alpha \cdot \mathcal{R}(\mathbf{D}_{dummy}) \quad (1)$$

- $\nabla W_{intercepted}$ ：截获的真实梯度更新。
- $\mathbf{D}_{dummy}$ ：攻击者构造的虚拟数据分布参数。
- $\mathcal{R}(\cdot)$ ：正则化项，用于确保生成分布的合理性。

关键洞察：该优化过程不涉及具体样本还原，只关注分布级别的参数。

4.1 击穿最强防御：为什么 DP 失效了？

实验观察：

- 个体的干扰：噪音很大时，单个样本的特征被完全模糊。
- 总体的抗噪性：“分布”是成千上万个样本的平均统计特性。
- 结论：零均值的高斯噪音在聚合过程中会相互抵消，宏观分布特征对 DP 噪音具有天然的鲁棒性。

Table 2: Accuracy of the property inference attack using different approaches in each experiment.

Experiment	Baseline (%)	Sorting (%)	Set-Based (%)
P^1_{Census}	55.0	89.0	97.0
P^2_{Census}	63.0	85.0	100.0
P^3_{Census}	93.0	100.0	100.0
P^1_{MNIST}	58.0	65.0	85.0
P^1_{CelebA}	67.7	80.2	99.8
P^2_{CelebA}	77.2	91.2	100.0
P^3_{CelebA}	77.2	90.8	100.0
P^4_{CelebA}	73.0	77.5	99.2
P^5_{CelebA}	74.6	84.7	98.8
P^1_{HPCs}	57.0	72.0	88.0

5.1 研究启示

核心结论 (Takeaways)

- **隐私保护的错位**：跨孤岛场景下，“宏观分布”往往比“微观记录”更具商业敏感性，但现有防御却无能为力。
- **PGDA 的威力**：首次证明了无需任何辅助数据，服务器就能以极高精度还原本地数据分布。

Q & A

感谢聆听！